

ПРОГНОЗИРОВАНИЕ ЧИСЛА СТРИМОВ ДЛЯ МУЗЫКАЛЬНЫХ ТРЕКОВ

КОМАНДА 5: АНДРЕЙ ЕРИЧЕВ, АНАСТАСИЯ ИВАНОВА, ЕЛИЗАВЕТА КУЗЬМИНЫХ, ПАВЕЛ СМИРНОВ

РУКОВОДИТЕЛЬ: АЛИСА ШИКАНЯН

ВШЭ Г. МОСКВА 2025

Цель и Задачи проекта

Цель

Исследовать зависимости числа стримов музыкального трека на платформе Spotify от набора признаков трека и на основании найденных зависимостей решить задачу линейной регрессии для прогнозирования числа стримов

Задачи



Выбрать датасет



Провести EDA



Проверить гипотезы



Построить модель



Дать рекомендации



Разведочный анализ данных. EDA

Источник данных

Kaggle: [Spotify and YouTube Music dataset](#)

Статистика по 10 лучшим песням различных исполнителей на Spotify и их видеоклипам YouTube

Структура данных

Датасет состоит из 16 полей и 20718 строк

Количественные признаки:

- danceability
- energy
- key
- loudness
- speechiness
- acousticness
- instrumentalness
- liveness
- valence
- tempo
- duration_min
- stream

Категориальные признаки:

- artist
- track
- album
- album_type

Очистка данных

Удалены следующие данные:

- Строки с пропусками
- Треки с белым шумом
- Аудиокниги
- Альбомы типа Compilation
- Треки длительностью более 7 минут
- Значения loudness вне допустимого диапазона (больше 0)

Удалены выбросы (по боксплоту):

- duration_min
- energy
- danceability
- tempo

Датасет после EDA и очистки состоит из 16 полей и 17968 строк



Разведочный анализ данных. EDA

Выводы по признакам

- Сильная положительная корреляция между **energy** и **loudness** (0.81)
- Сильная отрицательная связь между **energy** и **acousticness** (-0.77)
- Слабая положительная связь между логарифмом среднего количества прослушиваний (**in_stream**) и количеством композиций исполнителя (**track**)

Целевая переменная **stream** не имеет сильной связи с переменными.

Корреляционная матрица



Проверка гипотез



Треки из альбомов набирают больше стримов

Подтверждено критерием Манна–Уитни



Треки с приглашённым артистом (feat) набирают статистически значимо больше прослушиваний *

По результатам t-теста Уэлча

*Доп.задание



Комбинации параметров связаны с числом стримов

Подтверждено тестом Пирсона



Количество треков у артиста не влияет на стримы

По результатам линейной регрессии

Отбор признаков для моделей



Музыкальные признаки

Внутренние характеристики композиции

Danceability

Energy

Valence

Speechiness

Instrumentalness

Acousticness

Tempo

Loudness

Duration_min



Аналитические признаки

Факторы продвижения трека

is_feat

1 – если трек совместный
0 – иначе

is_album

1 – если трек входит в альбом
0 – иначе

Как выбирали признаки?

- По результатам EDA и статистических тестов
- По результатам проверки гипотез

Проблемы, с которыми столкнулись перед обучением моделей



Нет сильной связи между целевой переменной и параметрами



Не хватает дополнительных признаков (is_feat, is_album)

Зависимая переменная

Логарифм количества прослушиваний

Построение моделей. Результаты и метрики

I. Линейная регрессия

Линейная регрессия на всех признаках

R^2 на train: 7.99%
 R^2 на test: 7.93%

Мультиколлинеарность
Убрали признаки с $VIF >> 10$

R^2 на train: 7.14%
 R^2 на test: 6.99%

R^2 снизился
Пробуем регуляризацию, лучше не стало

R^2 на train: 7.14%
 R^2 на test: 6.99%

Добавляем полиномиальные признаки
Лучше справляется Ridge

Регрессия с полиномиальными признаками
и Ridge-регуляризацией

R^2 на train: 10.55%
 R^2 на test: 9.37%

2. Бустинговые модели

Light Gradient Boosting (LGBM)

R^2 на train: 17.3%
 R^2 на test: 10.49%

Подбор параметров через Optuna
 $n_estimators = 87, max_depth = 13$

R^2 на train: 37.7%
 R^2 на test: 12.91%

Стекинговая модель
XGBoost + CatBoost + LGBM

R^2 на train: 49.03%
 R^2 на test: 13.9%

R^2 значительно вырос как на train, так и на test...

НО! Модель явно переобучилась

Выводы



Энергичные, танцевальные треки, выпущенные как часть альбома или с участием приглашенного артиста, набирают больше прослушиваний



Целевая переменная *stream* не имеет сильной связи с другими переменными



Комбинации параметров имеют более сильную корреляцию с числом стримов, чем отдельные параметры



Качество текущих моделей необходимо повышать за счет дополнительных характеристик (жанры, год выхода композиции, дата релиза и т.д.)

Рекомендации

Текущие модели показывают **неудовлетворительные результаты**



Нет сильной связи между набором признаков трека и количеством прослушиваний

Что можно улучшить?

Частотность прослушиваний треков в чартах

Поведение пользователей в течение первых дней после релиза

Средняя динамика роста прослушиваний

Датасет Yambda

Идеи новых фич



Прогнозирование числа стримов для музыкальных треков

СЛЕВА ВЫ ВИДИТЕ НАШУ
КОМАНДУ №5 ЗА РАБОТОЙ
НАД ПРОЕКТОМ

	Андрей Еричев	Анастасия Иванова	Елизавета Кузьминых	Павел Смирнов
Сбор данных	Взяли готовый датасет			
EDA	+	+	+	+
Гипотезы	+	+	+	+
Построение модели	+			+
Доп. задание	+			
Презентация		+	+	+

Распределение обязанностей

	R² train	R² test	MSE train	MSE test
Линейная регрессия	7.99%	7.93%	2.4174	2.4307
Линейная регрессия без danceability, energy	7.14%	6.99%	2.4398	2.4554
Регуляризация + полиномиальные фичи	10.55%	9.37%	2.3501	2.3926
LightGBM	15.35%	9.87%	1.4913	1.5425
LightGBM + полиномиальные признаки	17.3%	10.49%	1.4741	1.5372
LGBM+Optuna	37.7%	12.91%	1.2794	1.5163
Стекинговая модель LGBM+XGBoost+CatBoost	49.03%	13.9%	1.1572	1.5077

ПРИЛОЖЕНИЕ //
Таблица с
результатами моделей